

Análise e planejamento estatístico de rotas

Introdução

A análise de rotas tem grande potencial para identificar pontos de vulnerabilidade em um rede de mobilidade urbana. Com o advento dos dados de torres de telefones celulares, dispomos hoje de dados ricos sobre padrões de movimento urbano através de dados de origem-destino (OD). Nesta lição prática, vamos utilizar análise estatística exploratória e modelos estatísticos para analisar rotas de mobilidade urbana em uma importante região metropolitana do Brasil.

Análise de rotas : dados origem-destino

Nesta seção vamos analisar dados de origem-destino apresentados em [Chaves et al. \(2023\)](#). Em essência, os dados descrevem o número de indivíduos que viajam entre duas localidades em um determinado período (no nosso caso, um dia). Além disso, temos a distância entre duas localidades medida de três formas diferentes: distância euclidiana, distância a pé (*walking*) e distância de carro (*driving*). Temos também as populações de cada área – ver modelo gravitacional abaixo.

O modelo gravitacional

Mais detalhes em [Santos et al. \(2019\)](#).

Seja F_{ij} o fluxo entre duas áreas (nós) i e j , e sejam P_i e P_j suas respectivas populações. Por fim, seja d_{ij} a distância entre os nós.

O modelo gravitacional diz que

$$F_{ij} = \alpha \cdot \frac{P_i \cdot P_j}{(d_{ij})^\gamma}, \quad (1)$$

onde α e γ são parâmetros livres a serem estimados. Nos exercícios propostos abaixo, você vai ajustar este modelo aos dados através de uma transformação que torna o problema de ajuste um problema de regressão.

Modelos lineares generalizados (GLM)

Sejam $\mathbf{Y} = (Y_1, \dots, Y_n)$ e \mathbf{X} o vetor de variáveis dependentes e a matriz $(n \times P)$ de desenho, respectivamente. Defina $\mu_i(\mathbf{X}) = \mu_i := E[Y_i | \mathbf{X}]$ como a média condicional de cada Y_i . Em um GLM, escrevemos

$$g(\mu_i) = \mathbf{X}\beta, \quad (2)$$

onde $g()$ é a chamada *função de ligação*, e é uma função monotônica e diferenciável. Por exemplo, quando $Y_i \in \{0, 1\}$, isto é, quando temos dados binários, podemos usar $g(\theta) = \log(\theta/(1 - \theta))$ ou $g(\theta) = \Phi^{-1}(\theta)$, onde Φ^{-1} é a CDF inversa de uma distribuição normal padrão. Além disso quando temos dados de contagem ($Y_i \in \{0, 1, \dots\}$) distribuídos Poisson – por exemplo –, é de costume usar $g(\theta) = \log(\theta)$.

Análise dirigida

1. Carregue os dados e investigue sua forma e dimensões.
2. Calcule as porcentagens de zeros em cada variável.
3. Filtre as entradas do banco correspondentes às entradas fora da diagonal na matriz origem-destino.
4. Investigue a correlação entre as variáveis de distância.
5. Sob o modelo gravitacional, mostre o que acontece quando consideramos a transformação $Z_i = \log(Y_i)$ e regredimos \mathbf{Z} em \mathbf{X} .
6. Ajuste o modelo transformado aos dados discutidos acima. Alguma das distâncias dá resultados melhores? Como as estimativas dos parâmetros mudam?
7. Avalie a qualidade do ajuste dos modelos ajustados.
8. Desenhe uma estratégia para avaliar o poder preditivo dos modelos em novas amostras.

Referências

- Chaves, Júlio César, Moacyr AHB da Silva, Ricardo de Souza Alencar, Alexandre G. Evsukoff, and Vinícius da Fonseca Vieira. [Human mobility and socioeconomic datasets of the Rio de Janeiro metropolitan area](#). Data in brief 51 (2023): 109695.
- Lima Santos, Leonardo Bacelar, Luiz Max Carvalho, Wilson Seron, Flávio C. Coelho, Elbert E. Macau, Marcos G. Quiles, and Antônio M. V. Monteiro. [How do urban mobility \(geo\) graph's topological properties fill a map?](#). Applied Network Science 4 (2019): 1-14.
- Evans, M. J., & Rosenthal, J. S. (2018). [Probability and Statistics - The Science of Uncertainty](#). CRC press. (Cap 10).

- Dobson, A. J., & Barnett, A. G. (2018). [An introduction to generalized linear models](#). CRC press. (Caps 3, 4 e 5)
- Gelman, A., Hill, J., & Vehtari, A. (2020). [Regression and other stories](#). Cambridge University Press. (Cap 15)