

# Análise e planejamento estatístico de rotas

## Introdução

A análise de rotas tem grande potencial para identificar pontos de vulnerabilidade em uma rede de mobilidade urbana. Com o advento dos dados de torres de telefones celulares, dispomos hoje de dados ricos sobre padrões de movimento urbano através de dados de origem-destino (OD). Nesta lição prática, vamos utilizar análise estatística exploratória e modelos estatísticos para analisar rotas de mobilidade urbana em uma importante região metropolitana do Brasil.

## Análise de rotas : dados origem-destino

Nesta seção vamos analisar dados de origem-destino apresentados em [Chaves et al. \(2023\)](#). Em essência, os dados descrevem o número de indivíduos que viajam entre duas localidades em um determinado período (no nosso caso, um dia). Além disso, temos a distância entre duas localidades medida de três formas diferentes: distância euclidiana, distância a pé (*walking*) e distância de carro (*driving*). Temos também as populações de cada área – ver modelo gravitacional abaixo.

### O modelo gravitacional

Mais detalhes em [Santos et al. \(2019\)](#).

Seja  $F_{ij}$  o fluxo entre duas áreas (nós)  $i$  e  $j$ , e sejam  $P_i$  e  $P_j$  suas respectivas populações. Por fim, seja  $d_{ij}$  a distância entre os nós.

O modelo gravitacional diz que

$$F_{ij} = \alpha \cdot \frac{P_i \cdot P_j}{(d_{ij})^\gamma}, \quad (1)$$

onde  $\alpha$  e  $\gamma$  são parâmetros livres a serem estimados. Nos exercícios propostos abaixo, você vai ajustar este modelo aos dados através de uma transformação que torna o problema de ajuste um problema de regressão.

## Modelos lineares generalizados (GLM)

Sejam  $\mathbf{Y} = (Y_1, \dots, Y_n)$  e  $\mathbf{X}$  o vetor de variáveis dependentes e a matriz  $(n \times P)$  de desenho, respectivamente. Defina  $\mu_i(\mathbf{X}) = \mu_i := E[Y_i | \mathbf{X}]$  como a média condicional de cada  $Y_i$ . Em um GLM, escrevemos

$$g(\mu_i) = \mathbf{X}\beta, \quad (2)$$

onde  $g()$  é a chamada *função de ligação*, e é uma função monotônica e diferenciável. Por exemplo, quando  $Y_i \in \{0, 1\}$ , isto é, quando temos dados binários, podemos usar  $g(\theta) = \log(\theta/(1 - \theta))$  ou  $g(\theta) = \Phi^{-1}(\theta)$ , onde  $\Phi^{-1}$  é a CDF inversa de uma distribuição normal padrão. Além disso quando temos dados de contagem ( $Y_i \in \{0, 1, \dots\}$ ) distribuídos Poisson – por exemplo –, é de costume usar  $g(\theta) = \log(\theta)$ .

## Análise dirigida

1. Carregue os dados e investigue sua forma e dimensões.
2. Calcule as porcentagens de zeros em cada variável.
3. Filtre as entradas do banco correspondentes às entradas fora da diagonal na matriz origem-destino.
4. Investigue a correlação entre as variáveis de distância.
5. Sob o modelo gravitacional, mostre o que acontece quando consideramos a transformação  $Z_i = \log(Y_i)$  e regredimos  $\mathbf{Z}$  em  $\mathbf{X}$ .
6. Ajuste o modelo transformado aos dados discutidos acima. Alguma das distâncias dá resultados melhores? Como as estimativas dos parâmetros mudam?
7. Avalie a qualidade do ajuste dos modelos ajustados.
8. Desenhe uma estratégia para avaliar o poder preditivo dos modelos em novas amostras.

## Referências

- Chaves, J. C. & da Silva, M.A.H.B. & Alencar, R.S. & Evsukoff, A.G & Vieira, V.F. [Human mobility and socioeconomic datasets of the Rio de Janeiro metropolitan area](#). Data in brief 51 (2023): 109695.
- Santos, L. B.L. & Carvalho, L.M. & Seron, W. & Coelho, F.C & Macau, E.E. & Quiles, M.G. & Monteiro, A.M.V. [How do urban mobility \(geo\) graph's topological properties fill a map?](#). Applied Network Science 4 (2019): 1-14.
- Evans, M. J., & Rosenthal, J. S. (2018). [Probability and Statistics - The Science of Uncertainty](#). CRC press. (Cap 10).

- Dobson, A. J., & Barnett, A. G. (2018). [An introduction to generalized linear models](#). CRC press. (Caps 3, 4 e 5)
- Gelman, A., Hill, J., & Vehtari, A. (2020). [Regression and other stories](#). Cambridge University Press. (Cap 15)